Microsoft Copilot: Your AI companion

copilot.microsoft.com/tasks/3cQ4TDwwZUPzhxJBf3fWs

Task:舆情监控开源项目深度调研（修正版）

为营销制作舆情监控与信息获取的开源项目，例如我发现了https://github.com/666ghj/BettaFish，还有更多其他的吗？如果我需要监控B站与Youtube还有哪些选择

好的，我来为你全面调研营销领域的舆情监控与信息获取开源项目，特别关注B站和YouTube的监控方案 。

调研综合舆情监控与信息获取开源项目

调研B站与YouTube专项监控开源工具

深入分析与对比各项目特性

生成完整调研报告文档

完整调研报告文档已生成，下面是核心发现的精要总结：

营销舆情监控开源项目全景图

当前开源舆情生态已形成清晰的**三层架构**：综合AI分析平台 → 多平台数据采集中间件 → 平台专项工具。除了你发现的 BettaFish，还有大量优质项目可供选择。

🏗️ 综合舆情分析平台

项目	Stars	核心能力	适用场景
BettaFish（微舆）	**40.3k**	4个AI Agent协作分析；覆盖10+国内社媒；自动生成8章级深度报告	品牌危机公关；竞品深度分析
sentiment_monitor	20	NLP情感分析；负面案例自动标注；预警通知	中小团队轻量舆情监控

📡 多平台数据采集中间件

项目	Stars	覆盖平台	亮点
MediaCrawler	**47.7k**	小红书；抖音；快手；**B站**；微博；贴吧；知乎（7平台全覆盖）	无需JS逆向；一二级评论；登录态缓存；IP代理池；词云生成

🎮 B站专项监控方案

项目	Stars	定位	营销价值
bilibili-api-python	**3.7k**	最完整的B站API封装库，全异步，覆盖视频/直播/动态/用户等全场景	底层API层：可编程获取播放量、弹幕、评论、收藏等核心指标
bilibili-comment-analyzer	**448**	专业B站评论分析工具，带GUI	**营销首选**：全国热力地图；智能词云；按地区/性别/等级多维筛选；品牌口碑地域差异分析
bili-spider	687	全站视频信息爬虫	历史数据批量采集（项目较老，需二次开发）
MediaCrawler B站模块	—	作为47.7k项目的子模块	与其他6平台共享统一基础设施

📺 YouTube专项监控方案

项目	Stars	定位	营销价值
yt-dlp	**155k**	命令行音视频下载器，支持数千网站	批量提取视频元数据（标题、标签、播放量、点赞数）；字幕提取用于内容分析

项目	Stars	定位	营销价值
youtube-comment-downloader	**1.2k**	无需API Key的YouTube评论下载器	**评论采集首选**：无配额限制；JSON输出；支持按热度/时间排序；可作为Python库调用
youtube-comment-suite	307	Java桌面端批量评论下载与搜索	多视频/播放列表/频道批量归档；全文搜索
utuby	小型	评论抓取+VADER情感分析一体化	快速原型：一行代码获取情感评分（正面/负面/中性/复合）
YouTube Data API v3	官方	谷歌合规接口	企业级合规监控；有每日10,000单位配额限制

🎯 推荐组合方案

你的需求	推荐组合
国内多平台舆情（含B站）	BettaFish（AI分析+报告）+ MediaCrawler（数据采集引擎）
B站深度分析	bilibili-api（数据获取层）+ bilibili-comment-analyzer（可视化分析）
YouTube深度分析	yt-dlp（视频元数据）+ youtube-comment-downloader（评论采集）+ 自建NLP情感分析
全域跨平台（B站+YouTube+国内社媒）	BettaFish + MediaCrawler + yt-dlp + youtube-comment-downloader，四件套组合

⚠️ 合规提醒

所有爬虫类项目均声明**仅供学习研究用途**，实际商用需：

- 遵守目标平台 robots.txt 和服务条款
- 控制请求频率，避免对目标服务器造成负担
- YouTube推荐优先使用官方 Data API v3（合规性最佳）
- B站通过 bilibili-api 调用官方接口比直接爬取更稳定合规

报告文档中包含了每个项目的详细技术架构、部署方式和GitHub地址，可直接参考选型。

营销舆情监控与信息获取开源项目调研报告

Generated

感觉你的分析不够准确，请仔细阅读bettafish当中的 https://github.com/666ghj/BettaFish/blob/main/MindSpider/README.md，当中谈到了：MindSpider是一个基于Agent技术的智能舆情爬虫系统，通过AI自动识别热点话题，并在多个社交媒体平台进行精准的内容爬取。系统采用模块化设计，能够实现从话题发现到内容收集的全自动化流程。 该部分学习借鉴github知名爬虫项目MediaCrawler 两步走爬取： 模块一：Search Agent从包括微博、知乎、github、酷安等 13个 社媒平台、技术论坛识别热点新闻，并维护一个每日话题分析表。 模块二：全平台爬虫深度爬取每个话题的细粒度舆情反馈。

你说得对，我之前的分析确实不够准确，把 BettaFish 和 MediaCrawler 当作平级独立项目来推荐了，实际上 BettaFish 的 MindSpider 模块本身就借鉴了 MediaCrawler。我现在深入阅读原始文档，重新做一份严谨的调研 。

深入阅读 BettaFish/MindSpider 原始文档，准确理解架构

调研B站与YouTube专项监控开源工具（验证准确性）

综合分析与对比，生成修正后的调研报告

Now I have a precise understanding of BettaFish's complete architecture. MindSpider 已经将 MediaCrawler 作为 git submodule 内嵌，而不是两个平级项目。接下来我要严谨调研 B站和 YouTube 的专项监控工具。

感谢你的纠正，让我重新梳理了 BettaFish 的真实架构。以下是基于源文档验证后的**修正版分析**。

修正后的核心认知：BettaFish 不是"分析工具"，而是一个完整的舆情操作系统

上一版分析最大的错误是将 BettaFish 和 MediaCrawler 视为平级独立项目来"组合推荐"。事实上，**MediaCrawler 已经作为 git submodule 内嵌在 BettaFish 的 MindSpider 模块中**，是 BettaFish 数据采集层的底层引擎。

BettaFish 真实架构（6大模块）

模块	职责	关键特征
MindSpider	AI驱动的智能爬虫系统	两步走架构：热点发现→深度爬取；内嵌 MediaCrawler 作为子模块
QueryEngine	国内外新闻广度搜索 Agent	具备反思机制的多轮搜索；15条结果上限

模块	职责	关键特征
MediaEngine	多模态内容分析Agent	短视频解析；结构化信息卡片（天气/股票等）提取
InsightEngine	私有数据库挖掘Agent	对接用户业务数据库；Qwen关键词优化；500条评论深度分析
ForumEngine	Agent间"论坛"协作机制	**独创设计**：引入LLM辩论主持人，让不同Agent链式思维碰撞，避免单一模型思维局限
ReportEngine	多轮报告生成Agent	模板选择→布局→篇幅→章节→IR中间表示→HTML/PDF/MD渲染

MindSpider 两步走架构详解

这是 BettaFish 数据采集的核心，不是简单爬虫，而是 **Agent 驱动的智能舆情采集系统**：

模块一：BroadTopicExtraction（话题发现）

- Search Agent 从 **13个** 社媒平台和技术论坛（微博热搜、知乎热榜、B站热门、今日头条、GitHub、酷安等）识别热点新闻
- 使用 DeepSeek API 对新闻进行AI分析，自动提取话题和关键词
- 维护一个**每日话题分析表**，存入 MySQL/PostgreSQL

模块二：DeepSentimentCrawling（深度爬取）

- 基于话题关键词，通过 **内嵌的 MediaCrawler**（git submodule）在 **7大平台** 进行深度爬取
- 覆盖：小红书(`xhs`)、抖音(`dy`)、快手(`ks`)、**B站**(`bili`)、微博(`wb`)、贴吧(`tieba`)、知乎(`zhihu`)
- 使用 Playwright 浏览器自动化，支持扫码登录、登录态缓存、IP代理池
- 提取帖子、评论、互动数据，进行情感倾向分析

关键启示：BettaFish **已经原生支持B站监控**，通过 MindSpider → DeepSentimentCrawling → MediaCrawler/media_platform/bilibili/ 实现。

那么，BettaFish 的能力边界在哪？

维度	覆盖情况	缺失/局限
国内社媒	✅ 30+平台（含B站）；热点发现+深度爬取完整闭环	需要各平台扫码登录

维度	覆盖情况	缺失/局限
B站深度分析	✅ 视频信息+评论爬取；情感分析（BERT/GPT-2/Qwen3微调模型）	无地域热力图可视化；无按性别/等级筛选
YouTube	❌ **完全不覆盖**	无YouTube平台实现
海外社媒	部分（QueryEngine可搜索海外新闻）	无Twitter/Reddit/Instagram等平台的深度爬取

B站监控：BettaFish 之外的补充方案

既然 BettaFish 已内置B站爬取，你需要的是**补充其不足的维度**：

bilibili-comment-analyzer（448 ⭐）

- **定位**：B站评论区专业可视化分析桌面工具
- **BettaFish 不具备的能力**：
  - 🗺️ **全国热力地图**：基于IP属地生成省份级评论分布，分析品牌地域口碑差异
  - 🔤 **智能词云**：中文分词+按地区/性别/等级多维筛选
  - 📊 **实时数据面板**：用户画像统计（等级分布、性别比例等）
- **支持**：BV号、EP号（番剧）、SS号、UP主批量分析
- **使用方式**：Windows exe直接运行，或源码 `poetry install` + `poetry run python run.py`

bilibili-api-python（3.7k ⭐）

- **定位**：最完整的B站API Python封装库，全异步
- **适合场景**：当你需要**编程式定制化**采集时（如自建监控Pipeline）
- 覆盖：视频/音频/直播/动态/专栏/用户/番剧等全场景
- 支持 `curl_cffi` 伪装浏览器 TLS/JA3 指纹，规避风控
- **注意**：这是底层API库，不含分析逻辑，需自行搭建上层应用

推荐策略

需求	方案
B站数据作为BettaFish全流程的一部分	直接使用 BettaFish 内置的 `--platforms bili`

需求	方案
B站评论的**地域分析和可视化**	bilibili-comment-analyzer（补充BettaFish的可视化短板）
自建B站监控服务/定制化需求	bilibili-api-python 作为底层SDK

YouTube监控：从零构建的工具链

BettaFish **完全不覆盖 YouTube**，这是你需要独立解决的领域：

第一层：数据采集

工具	Stars	用途	关键优势
yt-dlp	**155k**	视频元数据+字幕提取	支持数千网站；`--write-comments` 可导出评论；提取标题/标签/播放量/点赞数；字幕提取用于内容分析
youtube-comment-downloader	**1.2k**	专项评论下载	**无需 API Key**、无配额限制；按热度/时间排序；JSON输出；可作为Python库调用
YouTube Data API v3	官方	合规数据接口	企业合规首选；每日10,000单位配额；频道/视频/评论/搜索全覆盖

第二层：情感分析

工具	Stars	方案	特点
youtube-comment-sentimental-analysis	42	VADER情感分析 + Streamlit Web界面	开箱即用：输入视频链接→自动采集评论→情感分析→柱状图/散点图可视化
自建方案	—	youtube-comment-downloader + BettaFish的SentimentAnalysisModel	复用BettaFish的BERT/Qwen3微调模型处理YouTube中文评论

YouTube 推荐组合

Code

```
youtube-comment-downloader（评论采集，无API Key限制）
        ↓
yt-dlp --write-info-json（视频元数据补充）
        ↓
自建NLP分析层 或 youtube-comment-sentimental-analysis（情感分析）
```

合规建议：如果是企业级使用，YouTube Data API v3 是合规性最好的方案，但受每日配额限制。`youtube-comment-downloader` 适合研究和原型验证阶段。

修正后的全局认知图

Code

```
┌──────────────────────────────────────────────────────────┐
│                    BettaFish（微舆）                      │
│  ┌──────────┐ ┌──────────┐ ┌──────────┐                 │
│  │QueryEngine│ │MediaEngine│ │InsightEngine│  ← 3个分析Agent│
│  └──────┬───┘ └──────┬───┘ └──────┬───┘                 │
│         └────────────┴────────────┘                      │
│              ForumEngine（论坛协作/辩论）                  │
│                    ↓                                     │
│              ReportEngine → HTML/PDF/MD 报告              │
│                                                          │
│  ┌──────────── MindSpider ────────────┐                  │
│  │ BroadTopicExtraction (13平台热点)  │                  │
│  │         ↓ 每日话题表               │                  │
│  │ DeepSentimentCrawling (7平台深爬)  │                  │
│  │    └── MediaCrawler [submodule]    │                  │
│  │        ├── bilibili/ ← B站 ✅      │                  │
│  │        ├── xhs/douyin/kuaishou/    │                  │
│  │        └── weibo/tieba/zhihu/      │                  │
│  └────────────────────────────────────┘                  │
│  YouTube ❌ 不覆盖                                        │
└──────────────────────────────────────────────────────────┘

┌── YouTube 需独立解决 ──┐
│ yt-dlp (元数据+字幕)    │
│ youtube-comment-        │
│   downloader (评论)     │
│ VADER/自建NLP (分析)    │
└────────────────────────┘

┌── B站补充可视化 ────────┐
│ bilibili-comment-       │
│   analyzer (热力图+词云) │
└────────────────────────┘
```

核心结论

1. **BettaFish 是一个完整的舆情操作系统**，不是简单分析工具。它通过 MindSpider 内嵌 MediaCrawler 已经覆盖了B站在内的7大国内平台的采集+分析+报告全链路。
2. **B站监控**：BettaFish 已原生支持，但如果需要地域热力图/用户画像可视化，用 `bilibili-comment-analyzer` 补充。
3. **YouTube监控**：BettaFish 完全不覆盖，需要 `youtube-comment-downloader` + `yt-dlp` 独立构建采集链路，分析层可复用 BettaFish 的情感分析模型或用现成的 VADER 方案。
4. **之前推荐"BettaFish + MediaCrawler"组合是错误的**——MediaCrawler 已经是 BettaFish 的内部组件，不需要也不应该作为独立工具另外部署。

Wednesday

跟我们的营销总监沟通后，他有如下诉求：1.既定的跟踪名单，例如xxxslg游戏，ai可以协助扩充搜索词条 2.动态在各种平台，历史累积播放量最高的 以每周播放量热度 播放量，转发，点赞 了解视频的传播度 拿到评论当中进行语义分析 用户画像，可能需要这位用户还关注slg其他的的游戏 例如：用户去评判新产品，会进行跟自己玩的进行比较 传统的营销经验：年龄，地域，影响其实不大 更多的还是需要拿到这位用户的浏览记录，收藏夹，点赞等等信息 b站点赞，收藏，进行一定对其喜好度的分析 b站，抖音，快手，小红书，taptap，youtube

明白，营销总监的需求非常具体且深入，核心是围绕**SLG游戏赛道**做竞品舆情监控，重点在于**用户行为画像**而非传统人口统计学。我来逐一调研每个需求维度的技术可行性和开源工具支持。

调研各平台（B站/抖音/快手/小红书/TapTap/YouTube）的用户行为数据可获取边界

调研用户画像深度挖掘工具：收藏/点赞/关注列表/浏览记录的技术可行性

调研AI搜索词扩展与视频传播度分析的开源方案

生成面向营销总监的完整技术可行性报告

以下是基于深入调研的完整技术可行性分析报告，**逐一对应营销总监的每个诉求**，明确标注可行/部分可行/不可行：

一、AI辅助搜索词扩展 ✅ 完全可行

总监诉求：既定跟踪名单（如"xxx SLG游戏"），AI协助扩充搜索词条

技术方案

方案	原理	适用场景
BettaFish MindSpider 的 BroadTopicExtraction	DeepSeek API 对13个平台热点新闻做AI分析，自动提取话题和关键词	跟踪SLG赛道热点自动扩展
Query2doc（微软，EMNLP 2023）	用LLM对原始query生成"伪文档"，从中扩展语义相关词	提升搜索召回率
jina-ai/llm-query-expansion（68⭐）	LLM直接做query reformulation，支持同义词/关联词/长尾词扩展	快速原型验证

推荐实践：自建一个轻量Prompt Pipeline，输入"率土之滨"，让LLM输出：

- 同类竞品词：三国志战略版、万国觉醒、文明与征服、鸿图之下、寰宇之战
- 玩法关键词：SLG赛季、策略战争手游、行军打仗
- 用户搜索习惯词：率土攻略、率土开荒、SLG新手推荐
- 负面舆情词：率土充值坑、SLG氪金排行

这一步实现成本极低，调用任何LLM API即可。

二、视频传播度追踪 ✅ 完全可行

总监诉求：历史累积播放量最高、每周播放量、热度、播放量/转发/点赞，了解视频传播度

各平台可获取的视频指标

指标	B站	抖音	快手	小红书	TapTap	YouTube
播放量	✅ `view`	✅	✅	✅ 阅读数	N/A（非视频平台）	✅ `viewCount`
点赞数	✅ `like`	✅	✅	✅	✅ 评分	✅ `likeCount`
转发/分享	✅ `share`	✅	✅	✅	N/A	N/A（已隐藏）
收藏数	✅ `favorite`	✅	✅	✅	N/A	N/A
投币数	✅ `coin`	N/A	N/A	N/A	N/A	N/A

指标	B站	抖音	快手	小红书	TapTap	YouTube
弹幕数	✅ `danmaku`	N/A	N/A	N/A	N/A	N/A
评论数	✅ `reply`	✅	✅	✅	✅	✅ `commentCount`

实现"每周播放量增量"的方案

所有平台的API只返回**当前累计值**，不提供历史快照。实现周维度追踪需要：

Code

```
定时任务（每日/每周）
      ↓
采集目标视频当前各项指标
      ↓
写入时序数据库（如 InfluxDB / TimescaleDB / 简单CSV）
      ↓
周增量 = 本周快照 - 上周快照
```

采集工具对应关系

平台	推荐采集工具	获取视频指标的关键API/方法
B站	`bilibili-api-python` (3.8k⭐)	`video.Video(bvid).get_info()` 返回完整stat对象
抖音/快手/小红书	BettaFish → MediaCrawler（内嵌子模块）	各平台爬虫模块自动解析
TapTap	`taptap_emotion_analyse` (202⭐) 或自建爬虫	JSON API返回评分/评论数
YouTube	`yt-dlp --write-info-json`	提取 `view_count` / `like_count` 等字段

三、评论语义分析 ✅ 完全可行

总监诉求：拿到评论进行语义分析

现成方案

工具	覆盖平台	分析能力
BettaFish InsightEngine	B站/微博/知乎等7平台	BERT/GPT-2/Qwen3微调情感分析模型；500条评论深度分析；自动生成分析报告
taptap_emotion_analyse (202⭐)	TapTap	LSTM情感分析；pyecharts可视化；Word2Vec建模；支持扩充同类游戏数据集
bilibili-comment-analyzer (448⭐)	B站	全国热力地图；智能词云；地区/性别/等级多维筛选
youtube-comment-sentimental-analysis	YouTube	VADER情感分析 + Streamlit可视化

SLG游戏场景特化建议

总监提到"用户会跟自己玩的游戏进行比较"，这是一种**比较型评论**，需要专门的NLP处理：

Code

```
原始评论："率土之滨比三战好多了，至少不用氪那么多"
        ↓
提取结构化信息：
  - 提及竞品：三国志战略版（三战）
  - 比较维度：氪金程度
  - 情感倾向：正面（对率土）、负面（对三战）
  - 用户隐含画像：有三战游玩经验
```

这种分析BettaFish的通用情感模型无法直接完成，需要**定制微调**：

1. 用LLM（如DeepSeek/Qwen）做**命名实体识别**（识别游戏名）
2. 用LLM做**观点-目标对**提取（哪个游戏被夸/被踩）
3. 聚合统计竞品提及频率和情感倾向

四、⚠️ 用户画像深度挖掘——需要直面的硬性边界

总监诉求：拿到用户的浏览记录、收藏夹、点赞等信息；了解这位用户还关注哪些SLG游戏

残酷现实：6大平台用户行为数据的公开性

数据类型	B站	抖音	快手	小红书	TapTap	YouTube
浏览记录	🔴 私有	🔴 私有	🔴 私有	🔴 私有	🔴 私有	🔴 私有
收藏夹	🟡 用户设公开时可见	🔴 默认私密	🔴 默认私密	🟡 部分可见	N/A	🔴 私有
点赞/喜欢列表	🔴 仅自己可见	🟡 用户可选公开/私密	🟡 用户可选	🟡 部分可见	N/A	🔴 私有
关注列表	🟢 公开（需Cookie）	🟡 用户可选	🟡 用户可选	🟡 部分可见	🟢 公开	🟡 默认私有
发布内容/评论	🟢 公开	🟢 公开	🟢 公开	🟢 公开	🟢 公开	🟢 公开
玩过的游戏列表	N/A	N/A	N/A	N/A	🟢 **公开**	N/A

🟢 可获取 🟡 取决于用户隐私设置 🔴 不可获取

关键结论：

> **浏览记录在所有平台均为严格私有数据，任何第三方技术手段都无法获取。** 这不是技术难度问题，而是平台安全架构设计决定的——浏览记录只存在于平台服务端，不通过任何公开API或页面暴露。

替代方案：推断式用户画像构建

虽然不能直接获取用户的浏览记录，但可以通过**公开行为数据**反向推断用户的SLG兴趣画像：

Code

```
第一步：在SLG相关视频下采集评论 → 获得评论者UID列表
    ↓
第二步：逐一查询每个UID的公开数据
    ├── B站：公开收藏夹（bilibili-api-python → FavoriteList.get_content()）
    ├── B站：关注列表（API: /x/relation/followings?vmid=UID）
    ├── B站：投稿视频/动态（公开）
    ├── TapTap：用户主页「玩过的游戏」列表 ← ⭐最有价值
    └── 小红书：用户发布/收藏的笔记（部分可见）
    ↓
第三步：交叉分析
    ├── 该用户收藏夹中有多少SLG相关内容？
    ├── 该用户关注了哪些SLG游戏UP主？
    ├── 该用户在TapTap玩过哪些SLG游戏？（金矿！）
    └── 该用户的评论中提到了哪些竞品？
    ↓
输出：推断式SLG兴趣标签 + 竞品偏好矩阵
```

⭐ TapTap 是用户画像的最佳数据源

对于SLG游戏赛道，**TapTap是所有平台中用户画像数据最丰富的**，因为：

1. **用户主页的"玩过的游戏"列表是公开的**——可以直接看到一个用户玩过哪些SLG
2. **评论中包含评分和游玩时长**——可以量化用户对每款游戏的投入程度
3. **评论内容天然包含比较型表达**——"比XX好"/"不如XX"

开源工具：

- `taptap_emotion_analyse` (202⭐)：TapTap评论爬取+LSTM情感分析+pyecharts可视化
- `TapTapCommentCrawler` (Gitee)：支持游戏评论和厂商评论爬取
- 自建方案：TapTap的评论数据通过JSON API返回（`requests + BeautifulSoup`），技术门槛低

B站用户画像的可行路径

bilibili-api-python (3.8k⭐) 提供的用户数据接口：

接口	方法	数据	可行性
用户公开收藏夹	`get_video_favorite_list(uid)`	收藏夹列表（标题、数量）	✅ 如果用户设为公开

接口	方法	数据	可行性
收藏夹内容	`FavoriteList.get_content()`	收藏的具体视频	✅ 如果收藏夹设为公开
关注列表	API `/x/relation/followings`	关注的UP主/游戏官方号	✅ 需登录态Cookie
用户投稿视频	`user.User(uid).get_videos()`	用户发布的视频	✅ 完全公开
用户动态	`user.User(uid).get_dynamics()`	转发、分享等	✅ 完全公开
历史记录	API `/x/web-interface/history/cursor`	观看历史	🔴 仅限自己（需自己的SESSDATA）

实际可行的B站用户画像链路：

Code

```
某SLG视频下的评论者 UID = 12345678
      ↓
查询TA的关注列表 → 是否关注了"率土之滨官方号"、"三战情报站"等SLG相关UP主
      ↓
查询TA的公开收藏夹 → 收藏夹中是否有SLG攻略/测评视频
      ↓
查询TA的投稿/动态 → 是否转发过其他SLG内容
      ↓
综合判断：该用户是"率土+三战"双游玩家，偏好低氪玩法
```

五、六大平台覆盖方案总结

平台	内容监控	评论采集	情感分析	用户画像	推荐工具链
B站	✅ BettaFish内置	✅ MediaCrawler	✅ BettaFish InsightEngine	🟡 推断式（收藏夹+关注列表）	`BettaFish` + `bi` `api-python` + `bi` `comment-analyze`

平台	内容监控	评论采集	情感分析	用户画像	推荐工具链
抖音	✅ BettaFish内置	✅ MediaCrawler	✅ BettaFish	🔴 数据大部分私密	`BettaFish` （含MediaCrawler子模
快手	✅ BettaFish内置	✅ MediaCrawler	✅ BettaFish	🔴 数据大部分私密	`BettaFish` （含MediaCrawler子模
小红书	✅ BettaFish内置	✅ MediaCrawler	✅ BettaFish	🟡 发布/收藏笔记部分可见	`BettaFish` （含MediaCrawler子模
TapTap	⚠️ 需自建	✅ taptap_emotion_analyse	✅ LSTM模型	🟢 **玩过的游戏列表公开**	`taptap_emotion_` + 自建爬虫
YouTube	❌ BettaFish不覆盖	✅ youtube-comment-downloader	🟡 需自建NLP	🔴 数据大部分私密	`yt-dlp` + `youtu` `comment-downloa`

六、面向总监的核心结论

✅ 能做到的

1. **AI扩词**——给定"率土之滨"等种子词，LLM可自动扩展100+相关搜索词条
2. **全平台视频/内容监控**——播放量、点赞、转发、收藏、评论数，6个平台全覆盖
3. **每周增量追踪**——通过定时快照+差值计算实现
4. **评论情感分析**——正面/负面/中性分类；竞品提及识别
5. **TapTap用户游戏偏好画像**——通过公开的"玩过的游戏"列表直接获取

🟡 部分能做到（需要条件）

6. **B站用户SLG兴趣推断**——依赖用户是否将收藏夹设为公开（约30-50%用户会公开部分收藏夹）
7. **评论中竞品比较分析**——需要在BettaFish基础上做定制化NLP开发

🔴 做不到（技术硬限制）

8. **获取任何平台的用户浏览记录**——全平台严格私有，无任何技术手段可突破
9. **获取所有用户的完整收藏/点赞列表**——取决于每个用户的个人隐私设置，大量用户会设为私密
10. **YouTube用户订阅列表**——2024年起默认私有

🎯 建议的MVP落地路径

Code

```
Phase 1（2-4周）：BettaFish部署 + TapTap爬虫自建
  → 实现国内5平台内容监控 + TapTap用户游戏偏好画像
  → 定时快照实现周维度播放量追踪

Phase 2（4-6周）：YouTube采集链路 + 搜索词AI扩展
  → yt-dlp + youtube-comment-downloader
  → 接入LLM API做query expansion

Phase 3（6-8周）：深度NLP定制
  → 竞品比较型评论结构化提取
  → B站推断式用户画像（收藏夹+关注列表交叉分析）
  → 跨平台用户ID关联（同一用户在B站和TapTap的ID映射）
```

我现在要如何开始？我可能用claude帮我完成这个工程。但是目前各类爬虫分布在不同的github仓库。然后bettafish又是一个整体的解决方案（我暂时不需要这么大体量的）。数据就用简单的csv保存即可。帮我思考一个完整的解决方案，或者是给到claude的一个完整方案，他可以根据这个方案直接执行。那么我的方案如果需要如此之多的github开发仓库，那么我想不要随意的修改他们的代码。这样的话我后续也可以直接进行更新。

好的，我来为你设计一个**模块化、不修改第三方代码**的完整工程方案，可以直接交给Claude执行实现。我先调研各依赖库的实际调用方式，确保方案准确可执行。

调研各依赖库的实际编程接口与安装方式

设计模块化架构：Adapter模式隔离第三方代码

生成完整工程规格文档（可交付Claude直接执行）

文档已生成完毕，以下是这份**可直接交付Claude执行的工程规格书**的核心要点：

`slg-sentinel` 架构精要

三条铁律

1. **零侵入** — 所有第三方仓库通过pip包或git submodule引入，绝不修改源码，随时可 `pip upgrade` 或 `git submodule update --remote`
2. **Adapter隔离** — 每个平台一个Adapter类，是唯一需要编写的"胶水代码"
3. **CSV即数据库** — `data/{platform}/{data_type}/{YYYY-MM-DD}.csv` ，简单可靠

依赖隔离策略

平台	底层工具	引入方式	修改量
B站	`bilibili-api-python`	`pip install` 直接import	零
抖音/快手/小红书	MediaCrawler	`git submodule` + 子进程桥接	零
YouTube	`yt-dlp` + `youtube-comment-downloader`	`pip install` 直接import	零
TapTap	自建（`requests` + `BeautifulSoup`）	我们自己的代码	N/A

MediaCrawler桥接方案（最关键的设计决策）

MediaCrawler不是pip包，是standalone应用。文档中设计了**临时runner脚本方案**：

- 生成一段Python脚本，通过 `sys.path.insert` 引入MediaCrawler
- 在Python运行时用 `mc_config.PLATFORM = "dy"` 注入配置（不修改源文件）
- 通过 `subprocess.run()` 执行，读取MediaCrawler输出的CSV
- 临时脚本用完即删，MediaCrawler源码始终干净

交给Claude的执行顺序

文档中明确标注了**四个Phase**的实施路线：

Phase	周期	交付物
P0 骨架	Day 1-2	目录结构 + 数据模型 + CSVStore + CLI骨架
P1 采集层	Day 3-7	BilibiliAdapter + YouTubeAdapter + TapTapAdapter
P2 MediaCrawler 集成	Day 8-12	MediaCrawlerBridge + 抖音/快手/小红书Adapter
P3 分析层	Day 13-18	KeywordExpander + SentimentAnalyzer + UserProfiler + Scheduler

每个Phase都包含了**可验证的测试命令**，Claude可以在完成每个模块后立即验证正确性。

你可以直接将这份文档复制到Claude的对话中，告诉它"请按照这份规格书逐步实现"即可。需要我调整文档的任何部分吗？

SLG舆情监控系统工程规格说明书（Claude执行版）
Generated

mediacrawler能解决很多平台，在帮忙看看b站，youtube，taptap有什么github开源的解决方案。然后看看能否避免少的使用个人账号登陆（避免账号被封禁）

好的，我来深入调研B站、YouTube、TapTap三个平台的开源方案，重点关注**免登录/低风险**的采集方式。

调研B站开源爬虫/API工具及其登录要求
调研YouTube开源采集工具及免API Key方案
调研TapTap开源采集工具与API接口
整理各平台各数据维度的登录需求矩阵，更新工程规格文档

调研全部完成，以下是三个平台的完整工具链分析，**核心围绕"能不能不登录"**这个问题展开。

🔑 核心结论：登录需求矩阵

先给你最关键的一张表——**你需要的每项数据到底需不需要登录**：

B站

数据维度	免登录	需要的条件	推荐工具
视频基本信息（标题/播放量/点赞/投币/收藏/分享/弹幕数）	✅ 免登录	需Wbi签名（`bilibili-api-python`自动处理）	`bilibili-api-python`
搜索视频/用户	✅ 免登录	需Wbi签名	`bilibili-api-python`
热门/排行榜	✅ 免登录	无额外要求	`bilibili-api-python`
评论区（一级+二级）	✅ 免登录	需Wbi签名；未登录可能被限制到前几页	`bilibili-api-python`
用户公开信息（昵称/等级/粉丝数）	✅ 免登录	无额外要求	`bilibili-api-python`
用户公开收藏夹	🟡 **需Cookie**	需登录态才能访问其他用户收藏夹内容	`bilibili-api-python` + Credential
用户关注列表	🟡 **需Cookie**	需SESSDATA	`bilibili-api-python` + Credential
弹幕内容	✅ 免登录	XML实时弹幕免登录	`bilibili-api-python`
深度评论翻页（>20页）	🟡 **建议Cookie**	未登录容易触发风控；登录后更稳定	`bilibili-api-python` + Credential

YouTube

数据维度	免登录	需要的条件	推荐工具
搜索视频	✅ 免登录	无需API Key	`tubescrape`
视频元数据（标题/播放量/点赞/标签/描述）	✅ 免登录	无需API Key	`tubescrape` 或 `yt-dlp --write-info-json`
频道视频列表/Shorts	✅ 免登录	无需API Key	`tubescrape`
播放列表	✅ 免登录	无需API Key	`tubescrape`

数据维度	免登录	需要的条件	推荐工具
字幕/Transcript	✅ 免登录	无需API Key	`tubescrape`
评论采集	✅ 免登录	无需API Key	`youtube-comment-downloader`
评论+视频元数据一体化	✅ 免登录	无需API Key	`yt-dlp --write-comments --write-info-json`

YouTube是三个平台中最友好的——所有数据维度全部免登录、免API Key。

TapTap

数据维度	免登录	需要的条件	推荐工具
游戏评论（内容/评分/设备/游玩时长/昵称）	✅ 免登录	仅需User-Agent header	`taptap_emotion_analyse` 或自建requests
游戏基本信息	✅ 免登录	仅需User-Agent header	自建requests
评论支持度/反对度	✅ 免登录	API直接返回	`taptap_emotion_analyse`
用户"玩过的游戏"列表	✅ 免登录	用户主页公开数据	自建requests
热门游戏排行	✅ 免登录	webapiv2接口	自建requests

TapTap也完全免登录——它的 `api.taptapdada.com` 是纯公开JSON API，甚至不需要Cookie。

📦 三个平台的推荐工具链

B站：`bilibili-api-python`（3.8k⭐）

引入方式： `pip install bilibili-api-python`（零侵入，直接import）

为什么选它而不是MediaCrawler的B站模块：

维度	bilibili-api-python	MediaCrawler B站模块
登录要求	大部分接口**免登录**	**强制扫码登录**
封号风险	低（调官方REST API）	高（Playwright模拟浏览器）
安装方式	`pip install`	git submodule + 大量依赖
反爬处理	Wbi签名库自动处理；支持`curl_cffi`伪装TLS指纹	Playwright自动化（更容易被检测）
数据粒度	全异步API，精确控制每个字段	通用爬虫，字段固定
评论翻页	直接分页参数控制	模拟滚动，不稳定

关键代码示例（免登录）：

python

```python
import asyncio
from bilibili_api import video, search

async def main():
    # 免登录：获取视频完整信息（播放/点赞/投币/收藏/分享/弹幕数）
    v = video.Video(bvid="BV1xxxxx")
    info = await v.get_info()
    stat = info['stat']  # view, like, coin, favorite, share, danmaku,
reply

    # 免登录：搜索SLG相关视频
    results = await search.search("率土之滨 攻略")

    # 免登录：获取评论
    comments = await v.get_comments(page_index=1)

asyncio.run(main())
```

需登录的场景处理：

python

```
from bilibili_api import Credential

# 只在需要查用户收藏夹/关注列表时才用
credential = Credential(sessdata="xxx", bili_jct="xxx")
# 建议：使用小号，不要用主号
```

YouTube：`tubescrape` + `youtube-comment-downloader`

两个工具互补，**全部免登录、免API Key**：

工具	Stars	覆盖能力	引入方式	底层原理
tubescrape	4⭐（新项目）	搜索、频道浏览、字幕、播放列表；**不含评论**	`pip install tubescrape`	YouTube InnerTube API（官方内部API）
youtube-comment-downloader	1.2k⭐	评论专项采集（按热度/时间排序）	`pip install youtube-comment-downloader`	直接HTTP请求

为什么不只用yt-dlp：

- `yt-dlp` 的 `--write-comments` 功能可以导出评论，但它是作为视频下载器设计的，评论采集只是附带功能
- 大量采集评论时，`youtube-comment-downloader` 更专业、更稳定
- `tubescrape` 的搜索和频道浏览能力是 `yt-dlp` 不具备的

但保留 `yt-dlp` 作为备选：它155k⭐，是GitHub上最活跃的项目之一，稳定性无可匹敌，且 `--write-info-json` 导出的元数据最完整。

关键代码示例：

python

```
# tubescrape：搜索SLG游戏视频
from tubescrape import YouTube
with YouTube() as yt:
    results = yt.search('SLG game review', max_results=20, type='video')
    for v in results.videos:
        print(v.title, v.view_count, v.published_text)

# youtube-comment-downloader：采集评论
from youtube_comment_downloader import YoutubeCommentDownloader
downloader = YoutubeCommentDownloader()
comments = downloader.get_comments_from_url(
    'https://www.youtube.com/watch?v=xxxxx',
    sort_by=0  # 0=热度, 1=时间
)
for comment in comments:
    print(comment['text'], comment['votes'])
```

TapTap：自建最合理（API太简单，不需要第三方库）

为什么不用 `taptap_emotion_analyse` （203⭐）：

- 该项目6年前开发，Python 3.7环境，API端点 `api.taptapdada.com` 可能已变更
- 代码结构简单（就一个 `tap spider.py` ），核心逻辑一目了然
- **直接参考其API调用模式，在我们自己的Adapter中实现即可**

TapTap公开API结构（从源码验证）：

python

```
# 评论接口（免登录）
BASE_URL = 'https://api.taptapdada.com/review/v1/by-app'
params = {
    'app_id': '游戏ID',       # 如 34751（元气骑士）
    'sort': 'new',              # new=最新, hot=最热
    'from': 0,                  # 分页偏移量，每页10条，翻页+10
    'X-UA': 'V=1&PN=TapTap&VN_CODE=593&LOC=CN&LANG=zh_CN...'
}
headers = {
    'Host': 'api.taptapdada.com',
    'User-Agent': 'okhttp/3.10.0'  # 模拟APP请求
}
# 返回JSON包含：id, author.name, updated_time, device, spent(游玩时长),
#               score(评分), contents.text(评论内容), ups, downs
```

关键优势：990页上限（约9900条评论），足够覆盖任何SLG游戏的评论分析需求。

🔄 更新后的工程规格方案

综合以上调研，**更新之前给你的** `slg-sentinel` **方案的依赖策略**：

平台	之前方案	更新后方案	登录需求
B站	MediaCrawler子模块	`bilibili-api-python`（**pip install**）	基础采集免登录；深度用户画像需小号Cookie
抖音	MediaCrawler子模块	MediaCrawler子模块（不变）	需扫码登录（无法避免）
快手	MediaCrawler子模块	MediaCrawler子模块（不变）	需扫码登录（无法避免）
小红书	MediaCrawler子模块	MediaCrawler子模块（不变）	需扫码登录（无法避免）
YouTube	yt-dlp + youtube-comment-downloader	`tubescrape` **+** `youtube-comment-downloader`	🟢 **完全免登录**
TapTap	taptap_emotion_analyse	**自建Adapter（requests直接调API）**	🟢 **完全免登录**

封号风险等级总览

Code

```
🟢 零风险（免登录）
   ├── YouTube（tubescrape + youtube-comment-downloader）
   ├── TapTap（公开JSON API）
   └── B站基础数据（bilibili-api-python 免登录模式）

🟡 低风险（需Cookie但非模拟浏览器）
   └── B站用户画像（bilibili-api-python + 小号Credential）
       → 建议：注册专用小号，控制请求频率 ≤ 1次/秒

🔴 较高风险（Playwright模拟浏览器 + 扫码登录）
   └── 抖音/快手/小红书（MediaCrawler）
       → 建议：使用专用小号；每日限制采集量；启用IP代理池
       → 这三个平台目前没有免登录的开源替代方案
```

给Claude的方案变更要点

如果你要把更新后的方案交给Claude执行，核心变更是：

1. **B站Adapter**：从MediaCrawler桥接 → 改为直接 `from bilibili_api import video, search`，大幅简化
2. **YouTubeAdapter**：从yt-dlp → 改为 `tubescrape`（搜索/元数据） + `youtube-comment-downloader`（评论），两个pip包，代码量更少
3. **TapTapAdapter**：从引用第三方项目 → 改为自建（核心就是 `requests.get(api.taptapdada.com/...)`），代码最精简
4. **MediaCrawler只保留给抖音/快手/小红书**——这三个平台是唯一真正需要登录和模拟浏览器的

需要我把这些变更合并到之前那份工程规格文档中吗？

> 从yt-dlp → 改为 tubescrape（搜索/元数据） 这个不要这么改，我看到tubescrape的star数很少，还是优先考虑广泛开源仓库作为选取目标（小众的仓库可能比较新的，我觉得可以提取出他的好处，直接以抄代码的形式，而不是引用这个仓库），再者，我可能会将项目部署到github上，需要利用github的action

你说得对，tubescrape 太新了不适合作为依赖。我来重新调研YouTube成熟方案，并设计完整的GitHub Actions部署架构 。

调研YouTube成熟开源搜索/元数据方案（替代tubescrape）
调研GitHub Actions定时爬虫的最佳实践与限制
调研tubescrape的InnerTube API方案是否值得自建
更新工程规格文档：依赖策略 + GitHub Actions架构

调研发现了一个**架构级的关键问题**：MediaCrawler需要扫码登录，在GitHub Actions无头环境中完全不可行。这迫使我们必须采用**双模架构**。我来生成更新后的完整规格文档。

规格书v2已生成完毕。以下是本次更新的**关键架构变化**总结：

🔑 本次调研的三个核心发现

1. YouTube工具链定稿：三个成熟pip包，全部免登录

工具	Stars	角色	为什么需要
yt-dlp	155k	主力（搜索+元数据+评论）	`ytsearch:关键词` 搜索 + `extract_info(download=False)` 元数据；最稳定的YouTube数据提取工具

工具	Stars	角色	为什么需要
scrapetube	501	频道浏览补充	`get_channel(id, sort_by='popular')` 按播放量排序获取频道全部视频，yt-dlp做这个不如它直接；5年历史，491个项目在用
youtube-comment-downloader	1.2k	评论专项采集	大量评论采集时比yt-dlp的`--write-comments`更高效更稳定

关于tubescrape的处理：它的InnerTube API方案（`POST /youtubei/v1/search`，只依赖httpx）思路很好。规格书中已记录了这个调用模式——如果未来yt-dlp搜索被YouTube限制，可以参考tubescrape的源码**自建一个轻量搜索模块**，而不是引入这个4⭐的仓库作为依赖。

2. 双模架构——GitHub Actions的硬约束

调研中发现了一个**架构级问题**：MediaCrawler需要Playwright扫码登录 → 在GitHub Actions无头环境中**完全不可行**。

因此规格书将6个平台分为两类：

运行环境	平台	登录需求	采集工具
GitHub Actions（自动定时）	B站、YouTube、TapTap	🟢 全部免登录	bilibili-api-python / yt-dlp+scrapetube / 自建requests
仅本地/服务器	抖音、快手、小红书	🔴 需扫码登录	MediaCrawler（subprocess桥接）

3. 数据通过git push回data分支

Code

```
main分支 ← 源代码、配置、Actions工作流
data分支 ← CSV数据、周报（由Actions自动commit+push）
```

每个平台的cron错开30分钟，避免并发push冲突。GitHub Actions公开仓库**免费无限分钟**。

📋 交给Claude的操作指南

1. **将规格书文档完整复制到Claude对话中**
2. 告诉Claude："请按照这份规格书逐Phase实施，从Phase 0骨架开始"

3. 每个Phase完成后用文档中标注的**验证命令**确认正确性
4. Phase 0-3（采集层）完成后，先推送到GitHub验证Actions能否正常触发
5. 再继续Phase 4-5（分析层+进阶功能）

需要我对规格书的任何部分做调整吗？

SLG Sentinel 工程规格书 v2（双模架构 + GitHub Actions）
Generated